Machine Learning

11장 Ensemble Learning

고려대학교 통계학과
박유성

Contents

01 Ensemble Learning

02 Bagging, Pasting, 그리고

Random forest

03 Boosting

04 Gradient Boosting method의 해석

01 Ensemble Learning

- 앙상블 학습은 지금까지 배운 많은 종류의 분류기법(classifier)과 회귀기법(regression)들의 모임이며 이 기법들을 이용하여 예측 성능을 높이는 머신러닝을 말함.
- 많은 경우 분류기법에 다양하게 사용되기 때문에 분류를 중심으로 설명하겠음.

투표분류기법(Voting classifier)

- 가장 쉬운 앙상블 학습임.
- 2개 이상의 분류기법들을 동일한 데이터에 각각 적합 시킨 후 이를 이용해 새로운 자료에 대한 범주를 예측함.

  1) 범주를 예측하여 빈도가 가장 높은 범주로 할당

  → Hard voting

  2) 범주에 속할 확률을 예측하여 이 평균 확률이 가장 큰 범주로 할당

  → Soft voting
- 이러한 앙상블기법은 이용되는 분류기법들이 개념적으로 독립적인 경우에 효과가 높음.

02 Bagging, Pasting, 그리고 Random forest

- 앙상블기법은 대수의 법칙(Law of large number, LLN)에 기초함. 즉, 독립적인 분류기법이 많으면 분류의 정밀도가 높아진다는 의미임.

- 그러나 현재까지 개발된 분류기법의 종류가 LLN을 적용할 만큼 많지는 않고 서로 간에 독립인지 검정도 할 수 없음.

  → 적은 수의 분류기법을 사용하되 학습 데이터를 늘림.

  1) Bagging (Bootstrap aggregating)

  2) Pasting

  3) Random forest

Bagging과 Pasting

- 학습 데이터의 크기가 n이라면 이 학습 데이터에서 크기가 n개의 표본을 뽑아 M개의 새로운 학습 데이터를 생성함.
  1) with replacement → Bagging
  2) without replacement → Pasting

- 분류를 할 때는 hard voting 또는 soft voting을 이용하여 분류함.
  회귀를 할 때는 각 특성변수 별로 예측된 값들을 평균해 예측 값으로 함.

- 일반적으로 bagging을 주로 사용함.

- Bagging을 할 경우 새로운 학습 데이터에 포함 되지 않는 데이터가 존재할 수 있는데 이 뽑히지 않은 데이터를 out-of-bag (oob)라고 함. Oob는 검증데이터로 이용할 수 있음.

Bagging과 Pasting

- 예를 들어 목표변수를 2개의 범주로 분류하고자 하며

  3가지 분류기법을 이용하고 $M = 100$이라면

  1) 3가지 분류기법을 이용해 각각 100번의 예측 값을 산출.

     즉, 시험데이터에 대하여 총 300번의 예측을 하게 됨.

  2) 분류일 경우

     hard voting : 300번의 할당 중 가장 많이 할당된 값이 예측 값

     soft voting : 300번의 예측 확률을 평균을 내어 가장 큰 평균 값을
     갖는 범주가 예측 값.

     회귀일 경우

     300개의 목표변수 예측 값의 평균이 예측 값.

Random forest

- 의사결정나무의 bagging 버전임.

- 분석 절차

  크기가 n이고 d개의 특성변수를 가진 원래의 학습 데이터를 이용할 경우

  1) n개의 확률 붓스트랩 표본을 뽑아 새로운 학습 데이터를 생성함.

  2) 새로운 학습 데이터를 이용해 각 노드마다 d개의 특성변수 중 임의로 k개의 특성변수를 뽑은 후 이 k개의 변수에 대해서 일반적인 의사결정나무를 완성함.

  3) 절차 1-2를 M번 반복함.

  4) M개의 의사결정나무 결과에 의해 분류일 경우에는 voting, 회귀일 경우에 평균을 취하여 예측 값으로 함.

- 가지치기는 필요하지 않고 보통 $k=\sqrt{d}$ 으로 하며 M은 가능한 크게 택함.

03 Boosting

- Boosting은 개선함(to improve)를 뜻함.
- Weak learner를 여러 번 사용하여 성능을 높이는 방법임.
- 분석 절차

  1) weak learner를 이용해 분류한 후 n개의 학습 데이터 중

     분류가 올바르게 된 학습 데이터 → 가중치 줄임

     오분류된 학습 데이터 → 가중치 높임

  2) 1)을 M번 반복함.

     이때 L_i 를 i 번째 learner라고 하면 learner는 $L = \sum_{i=1}^{M} L_i$ 이 됨.
- 이처럼 추가적(addictive)으로 개선되는 방법을 boosting이라 함.

전향적 모델링(Forward stagewise modeling)

- 알고리즘

1. $f_0(\underline{x}) = \beta_0$

2. $m = 1$부터 M까지

   a. $\sum_{i=1}^{n} L[y_i, f_{m-1}(\boldsymbol{x}_i) + \beta b(\boldsymbol{x}_i, \gamma)]$를 최소화 하고 최소화한 β와 γ를 (β_m, γ_m)으로 표기함. 이때 L은 손실함수임.

   b. $f_m(\boldsymbol{x}) = f_{m-1}(\boldsymbol{x}) + \beta_m b(\boldsymbol{x}, \gamma_m)$으로 최신화함.

- 이때 $b(\boldsymbol{x}, \gamma_m)$는

  – 로지스틱 회귀 : $b(\boldsymbol{x}, \gamma) = (1 + \exp(-\boldsymbol{x}^T\gamma))^{-1}$

  – 선형회귀모형 : $b(\boldsymbol{x}_i, \gamma) = x_{im}$

  – 의사결정나무 : $b(\boldsymbol{x}_i, \gamma) = I(\boldsymbol{x}_i \in R_\gamma)$, γ은 선택된 노드, R_γ는 영역

전향적 모델링(Forward stagewise modeling)

- 만약 손실함수가 제곱오차 손실함수라면,

$$\sum_{i=1}^{n} L(y_i, f_{m-1}(\boldsymbol{x}_i) + \beta b(\boldsymbol{x}_i, \gamma)) = \sum_{i=1}^{n} (y_i - f_{m-1}(\boldsymbol{x}_i) - \beta b(\boldsymbol{x}_i, \gamma))^2$$

$$= \sum_{i=1}^{n} (r_i - \beta b(\boldsymbol{x}_i, \gamma))^2$$

- 이때 회귀모형을 가정하면 $b(\boldsymbol{x}_i, \gamma) = x_{im}$이 되며

  $m = j\ (j = 1, \dots, M)$일 때 $\beta_j x_{ij}$로 회귀하는 것은 M번 반복하면

  $f_M(\boldsymbol{x}) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_M x_M$ 이 되는데 이는 일반적인 OLS와 다름.

4가지 손실함수에 대한 최소 f의 기댓값

손실함수	Cost	미분	f^*
제곱오차	$(y_i - f(\boldsymbol{x}_i))^2$	$y_i - f(\boldsymbol{x}_i)$	$E(y \mid \boldsymbol{x}_i)$
절대오차	$\lvert y_i - f(\boldsymbol{x}_i) \rvert$	$\text{sign}\lvert y_i - f(\boldsymbol{x}_i) \rvert$	$\text{median}(y \mid \boldsymbol{x}_i)$
지수	$\exp(-\tilde{y}_i f(\boldsymbol{x}))$	$-\tilde{y}_i exp(-\tilde{y}_i f(\boldsymbol{x}_i))$	$\frac{1}{2} log \frac{\pi_i}{1-\pi_i}$
로짓	$\log(1+\exp(-y_i f(\boldsymbol{x}_i)))$	$y_i - \pi_i$	$\frac{1}{2} log \frac{\pi_i}{1-\pi_i}$

- 지수와 로짓은 이항분류를 위한 손실함수이며 $\tilde{y}_i = \{-1, 1\}$, $y_i = \{0, 1\}$, $\pi_i = (1+e^{-2f(\boldsymbol{x}_i)})$이 됨. 로짓 손실함수의 증감이 지수보다는 좀 더 선형임.
- 제곱오차와 절대오차는 일반적으로 실수 자료에 대한 회귀에 쓰임.

4가지 손실함수에 대한 최소 f의 기댓값

- 지수 손실함수에 대한 f^*

$L = \exp(-\tilde{y}f)$ 이므로 $\frac{\partial L}{\partial f} = -\tilde{y}\exp(-\tilde{y}f)$이고

$E(-\tilde{y}exp(-\tilde{y}f)|\boldsymbol{x}_i) = -\exp(-f)P(\tilde{y}=1|\boldsymbol{x}_i) + \exp(f)P(\tilde{y}=-1|\boldsymbol{x}_i)$ 이므로

$E(\frac{\partial L}{\partial f}) = 0$ 인 해는 $f^* = \frac{1}{2}log\frac{P(\tilde{y}=1|\boldsymbol{x}_i)}{P(\tilde{y}=-1|\boldsymbol{x}_i)}$ 이 됨.

그러므로 $P(\tilde{y}=1|\boldsymbol{x}_i) > 0.5$ (즉, $f^*(\boldsymbol{x}_i) > 0$)이면 범주는 1로 예측하게 됨.

4가지 손실함수에 대한 최소 f의 기댓값

- 로짓 손실함수에 대한 f^*

로지스틱 회귀에서는 $p_i = P(\tilde{y} = 1|\boldsymbol{x}_i) = \dfrac{1}{1+e^{-2f(\boldsymbol{x}_i)}}$ 임. 이때 $f(\boldsymbol{x}_i) = \dfrac{1}{2}\boldsymbol{w}^T\boldsymbol{x}_i$ 임.

$y = (\tilde{y}+1)/2$ 로 변환하면 $\tilde{y} = 1$ 일 때 $y = 1$, $\tilde{y} = -1$ 일 때 $y = 0$이 됨.

로그우도함수는

$$l = y\log p_i + (1-y)\log(1-p_i) \tag{11.1}$$

이때 $p_i = (1+e^{-2f(\boldsymbol{x}_i)})^{-1}$이므로 위 식을 정리하면 $l = -\log(1+e^{-2yf(\boldsymbol{x}_i)})$이 됨.

따라서 손실함수는 $-l = L = \log(1+e^{-2yf(\boldsymbol{x}_i)})$이 되며 이는 로짓 손실함수와 같음.

AdaBoost

- 지수손실함수를 이용한 전향적모델링의 전형적인 응용임.

- AdaBoost의 손실함수

$$\sum_{i=1}^{n} \exp(-y_i(f_{m-1}(\boldsymbol{x}_i)+\beta b(\boldsymbol{x}_i,\gamma))) = \sum_{i=1}^{n} w_i^{(m)} \exp(-\beta y_i b(\boldsymbol{x}_i,\gamma)) \quad (11.2)$$

  이때 $y_i \in \{-1,1\}$, $w_i = \exp(-y_i f_{m-1}(\boldsymbol{x}_i))$ 임.

- $f_{m-1}(\boldsymbol{x}_i)$는 $(m-1)$번째 단계에서 계산된 classifier로

  $y_i f_{m-1}(\boldsymbol{x}_i)$가 음의 방향으로 클수록 $w_i^{(m)}$가 커지게 됨.

- 전단계인 $(m-1)$번째 단계에서 예측오차가 큰 학습 데이터에 가중치 부여

  → 현단계에서 큰 가중치를 제대로 분류하도록 오차를 최소화 하는

  β와 γ를 추정하게 됨.

AdaBoost

- 추정

$\beta > 0$을 고정시키고 AdaBoost의 손실함수를 최소로 하는 $b(\boldsymbol{x}_i, \gamma)$를 구하면

$$\begin{aligned} L &= \sum_{i=1}^{n} w_i^{(m)} \exp(-\beta y_i b(\boldsymbol{x}_i, \gamma)) \\ &= \sum_{y_i = b(\boldsymbol{x}_i, \gamma)} w_i^{(m)} e^{-\beta} + \sum_{y_i \neq b(\boldsymbol{x}_i, \gamma)} w_i^{(m)} e^{\beta} \\ &= (e^{\beta} - e^{-\beta}) \sum_{i=1}^{n} w_i^{(m)} I(y_i \neq b(\boldsymbol{x}_i, \gamma)) + e^{-\beta} \sum_{i=1}^{n} w_i^{(m)} \end{aligned} \tag{11.3}$$

즉, $\sum_{i=1}^{n} w_i^{(m)} I(y_i \neq b(\boldsymbol{x}_i, \gamma))$를 최소화 하는 것이 되며 w_i^m 가 주어져 있으므로

$b(\boldsymbol{x}_i, \gamma)$는 낮은 깊이를 가진 분류나무나 로지스틱 회귀를 이용하여 구하며

이를 $b_m(\boldsymbol{x}_i, \gamma)$이라 하고 (11.3)을 최소화 하는 β를 구하면

AdaBoost

- 추정(계속)

$$\beta_m = \frac{1}{2} log \frac{1-e_m}{e_m}, \quad e_m = \frac{\sum_{i=1}^{n} w_i^{(m)} I(y_i \neq b_m(\boldsymbol{x}_i, \gamma))}{\sum_{i=1}^{n} w_i^{(m)}} \tag{11.4}$$

$f_m(\boldsymbol{x}_i) = f_{m-1}(\boldsymbol{x}_i) + \beta_m b_m(\boldsymbol{x}_i, \gamma)$ 이므로 $w_i^{(m+1)} = w_i^{(m)} e^{\beta_m y_i b_m(\boldsymbol{x}_i, \gamma)}$ 이 되며

$y_i b_m(\boldsymbol{x}_i, \gamma) = 2I(y_i \neq b(\boldsymbol{x}_i, \gamma)) - 1$ 이므로 $w_i^{(m+1)} = w_i^{(m)} e^{2\beta_m I(y_i \neq b(\boldsymbol{x}_i, \gamma))} e^{-\beta_m}$ 임.

이때 $e^{-\beta_m}$는 모든 학습 데이터에 부여된 값이므로 $w_i^{(m+1)} = w_i^{(m)} e^{\beta_m I(y_i \neq b(\boldsymbol{x}_i, \gamma))}$ 임.

AdaBoost

- 알고리즘

1. $f_0(\underline{x}) = 0$ 로 설정함($w_i^{(0)} = 1/n, \;\; i = 1, 2, \ldots, n$)

2. $m = 1$ 부터 M 까지

   a. $\sum_{i=1}^{n} w_i^{(m)} I(y_i \neq b(\boldsymbol{x}_i, \gamma))$를 최소화하는 β_m와 $b_m(\boldsymbol{x}_i, \gamma)$를 구함.

   b. (11.4)에서 정의된 β_m과 e_m을 구한 후 $\alpha_m = 2\beta_m$으로 놓음.

   c. $w_i^{(m+1)} = w_i^{(m)} \exp(\alpha_m I(y_i \neq b_m(\boldsymbol{x}_i, \gamma))$를 계산.

3. $b_m(\boldsymbol{x}_i, \gamma)$으로 $\boldsymbol{x}_i$에 대응하는 목표변수의 범주를 -1 또는 1로 예측함.

분석 전 고려할 사항들

1. 자료의 타입에 민감한가?

   : 자료의 타입은 실수, 명명형, 범주형 등이 있음.

2. 결측 자료에 민감한가?

3. 자료의 이상치에 민감한가?

   : 손실함수가 제곱오차일 경우 민감함.

4. 자료의 표준화가 필요한가?

   : 특성변수의 scale 문제 때문임. 하지만 변환은 정보의 손실 또는 왜곡을 초래해 해석에 문제를 일으킬 수 있음.

5. 해석의 용이성

6. 성능

Learning 방법의 특성들의 비교

특성	로지스틱	KNN	LDA	SVM	의사결정나무	최소제곱 선형모형	Neural network
자료 type 민감성	상	상	상	상	하	상	상
결측 자료 영향	상	중	상	상	하	상	상
이상치 민감성	상	하	상	상	하	상	상
선형 변환	불필요	불필요	불필요	불필요	불필요	불필요	필요
해석의 용이성	용이	난해	난해	난해	용이	용이	매우난해
성능	높음	중간	중간	높음	중하	중간	높음

- 주어진 자료에 적절한 분석 도구를 선택해야 함.
- 분석자료의 준비과정이 필요 없는 off-the-shelf 분석 방법은 의사결정나무임.
- Gradient Boosted method (GBM)은 의사결정나무의 예측성능을 높임.

Gradient Boosting

- 전향적 모델링의 응용임.
- 의사결정나무
  - 의사결정나무에서 $b(\boldsymbol{x},\boldsymbol{\gamma})=\sum_{j=1}^{J}\gamma_j I(\boldsymbol{x}\in R_j)$ 이고

    이때 $\{\gamma_j, R_j\},\ \ j=1,2,...,J$ 이며 R_j는 노드 γ_j에 만들어진 영역임.
  - 불순도 측도를 이용하여 R_j를 top-down 형태로 결정하고

    회귀나무는 R_j에 포함된 y_i들의 평균을 추정치로

    분류나무는 R_j 안에 가장 많은 범주를 추정치로 함.

Gradient Boosting

- 의사결정나무(계속)

  – 그런데 회귀나무에서 주로 사용하는 제곱오차나 절대오차 손실함수 등으로

$$\sum_{i=1}^{n} L(y_i, \sum_{j=1}^{J} \gamma_j I(\boldsymbol{x}_i \in R_j)) \tag{11.5}$$

  를 최소로 하는 γ_j, R_j를 구하는 것은 어려움.

Gradient Boosting

- 일반적인 $f(\boldsymbol{x}_i)$

  – 손실함수가 미분 가능하다고 가정하면

$$\sum_{i=1}^{n} L(y_i, f(\boldsymbol{x}_i)) \tag{11.6}$$

  를 최소화 하는 $f(\boldsymbol{x}_i)$를 구하게 됨.

  – (11.6)에 기울기 하강법을 적용하면

$$\begin{aligned} f_m(\boldsymbol{x}_i) &= f_{m-1}(\boldsymbol{x}_i) - \eta_m \frac{\partial L(y_i, f(\boldsymbol{x}_i))}{\partial f(\boldsymbol{x}_i)}\Big|_{f(\boldsymbol{x}_i = f_{m-1}(\boldsymbol{x}_i))} \\ &= f_{m-1}(\underline{x_i}) - \eta_m g_{im} \end{aligned} \tag{11.7}$$

  이 되고 여기서 $i = 1, 2, \ldots, n$ 이고 $g_{im} = \frac{\partial L(y_i, f(\boldsymbol{x}_i))}{\partial f(\boldsymbol{x}_i)}\Big|_{f(\boldsymbol{x}_i = f_{m-1}(\boldsymbol{x}_i))}$ 임.

Gradient Boosting

- 일반적인 $f(\boldsymbol{x}_i)$ (계속)

  – (11.6)의 $f(\boldsymbol{x}_i)$에 $f_m(\boldsymbol{x}_i)$를 대입하면

$$\sum_{i=1}^{n} L(y_i, f_{m-1}(\underline{x_i}) - \eta_m g_{im}) \tag{11.8}$$

  이 됨. 전향적 모델링에서 $\sum_{i=1}^{n} L[y_i, f_{m-1}(\boldsymbol{x}_i) + \beta b(\boldsymbol{x}_i, \boldsymbol{\gamma})]$ 의

  $\beta_m = \eta_m$, $b(\boldsymbol{x}_i, \boldsymbol{\gamma}_m) = g_{im}$ 이 됨을 알 수 있음.

- (11.5)를 최소화 하는 γ_j , R_j

  – (11.7)의 g_{im}을 구한 후,

$$\sum_{i=1}^{n} (-g_{im} - \sum_{j=1}^{J} \gamma_{jm} I(\boldsymbol{x}_i \in R_{jm}))^2 \tag{11.9}$$

  을 최소화 하는 γ_{jm}을 산출함. R_{jm}은 의사결정나무의 불순도 측도 이용해 추정.

Gradient Boosting

- (11.5)를 최소화 하는 γ_j , R_j (계속)

  – (11.9)는 (J−1)개의 더미변수를 가진 일반적인 회귀모형의 손실함수이며 γ_{jm} 은 최소제곱 추정치가 됨. g_{im} 이 기울기이기 때문에 gradient boosting으로 불림.

  – η_m 은 적절한 손실함수 L에 의해 정의된 (11.8)에 의해

$$\sum_{i=1}^{n} L(y_i, f_{m-1}(\underline{x_i}) + \eta_m \sum_{j=1}^{J} \hat{\gamma}_{jm} I(\boldsymbol{x}_i \in R_{jm}))$$

  을 최소화 하는 η_m 을 구함. 이때 $\hat{\gamma}_{jm}$ 은 (11.9)에 의한 최소제곱추정치임.

- (11.8)에서 가장 많이 사용되는 손실함수를 정리하면 다음 표와 같음.

Gradient Boosting

- 손실함수와 기울기

도구	Loss	$-\partial L/\partial f(x_i)$	비고
회귀	$\sum_{i=1}^{n}(y_i-(f\boldsymbol{x}_i))^2$	$y_i-f(\boldsymbol{x}_i)$	제곱오차
	$\sum_{i=1}^{n}\lvert y_i-f(\boldsymbol{x}_i)\rvert$	$sign\lvert y_i-f(\boldsymbol{x}_i)\rvert$	절대오차
	$(y_i-f(\boldsymbol{x}_i))^2 \text{ if } \lvert y_i-f(\boldsymbol{x}_i)\rvert<\delta$ $2\delta\lvert y_i-f(\boldsymbol{x}_i)\rvert-\delta^2 \text{ if } \lvert y_i-f(\boldsymbol{x}_i)\rvert\geq\delta.$	$y_i-f(\boldsymbol{x}_i) \text{ if } \lvert y_i-f(\boldsymbol{x}_i)\rvert<\delta$ $\delta\, sign\lvert y_i-f(\boldsymbol{x}_i)\rvert \text{ if } \lvert y_i-f(\boldsymbol{x}_i)\rvert\geq\delta$	후버손실
분류	$-\sum_{k=1}^{K}I(y_i\in g_k)\log p_k(\boldsymbol{x}_i)^*$ $=-\sum_{i=1}^{K}I(y_i\in g_k)f_k(\boldsymbol{x}_i)$ $+\log(\sum_{k=1}^{K}e^{f_k(\boldsymbol{x}_i)})$	$\frac{\partial L}{\partial f(\underline{x_i})}=I(y_i\in g_k)-p_k(\boldsymbol{x}_i)$	Deviance loss =음의 다항분포 우도함수

* $p_k(\underline{x})=e^{f_k(x)}/\sum_{k=1}^{K}e^{f_k(x)}$, g_k 는 k번째 그룹

Gradient Tree Boosting

- Gradient tree boosting 알고리즘

1. 초기치 $\sum_{i=1}^{n} L(y_i, \gamma)$를 최소화하는 $f_0(\underline{x}) = \gamma$

2. $m=1$ 부터 M 까지

   a. $g_{im} = -\left[\frac{\partial L(y_i, f(\boldsymbol{x}_i))}{\partial f(\boldsymbol{x}_i)}\right]_{f=f_{m-1}}, \ i=1,2,\dots,n$

   b. $\sum_{i=1}^{n}(-g_{im} - \sum_{j=1}^{J} \gamma_{jm} I(\boldsymbol{x}_i \in R_{jm}))^2$ 를 최소화하는 $\hat{\gamma}_{jm}$ 을 구함. 이때 R_{jm} 은 의사결정나무의 불순도측도에 의해 결정된 J개의 서로 배반인 영역.

   c. $\sum_{i=1}^{n}(y_i, f_{m-1}(\boldsymbol{x}_i) + \eta_m \sum_{j=1}^{J} \hat{\gamma}_{jm} I(\boldsymbol{x}_i \in R_{jm}))$을 최소화 하는 η_m을 구함.

   d. $f_m(\boldsymbol{x}_i) = f_{m-1}(\boldsymbol{x}_i) + \widehat{\eta_m} \sum_{j=1}^{J} \hat{\gamma}_{jm} I(\boldsymbol{x}_i \in R_{jm})$으로 업데이트.

3. $\hat{f}(\boldsymbol{x}_i) = f_M(\boldsymbol{x}_i)$

Gradient Tree Boosting

- 알고리즘에서는 J를 고정했지만 반복에 의존하도록 설정해도 됨.
- 총 범주가 K일 때, Gradient tree boosting은 2-a~2-d를 K번 반복하여 $f_k(\boldsymbol{x}_i), \quad k=1,\ldots,K$ 를 구함.
- $f_M(\underline{x_i})$ 는 class 숫자만큼 K개가 산출되어 $p_k(\boldsymbol{x}_i)=\frac{e^{f_k(\boldsymbol{x}_i)}}{\sum_{k=1}^{K} e^{f_k(\boldsymbol{x}_i)}}$ 에 의해 범주 k에 속할 확률을 예측 가능.
- GBM 알고리즘에 사용된 의사결정나무의 크기인 J는 일반적으로 $4 \leq J \leq 8$.

04 GBM의 해석

- 덧셈 방식의 boosting에 의한 의사결정 나무는 별도의 해석도구가 필요함.

  1) 상대중요도(relative importance)

  - 회귀

    GBM에서는 나무회귀를 M번 반복하므로 특성변수 별로 줄어든

    오차제곱합의 평균을 구한 후 평균이 가장 큰 변수를 100으로 놓고

    나머지 변수의 상대 중요도를 구함.

  - 분류

    나머지는 회귀와 동일하며 오차제곱합 대신 information gain을 이용함.

04 GBM의 해석

- 2) 부분의존플롯(partial dependence plot)
  - 선형회귀모형에서의 회귀계수와 같은 역할을 함
  - 관심 있는 특성변수의 다양한 값에 대해 $f_M(\boldsymbol{x}_i)$ 을 그림.
  - 예를 들어 X_1 변수가 관심변수라면,

    X_1 은 x축, $f_M(\boldsymbol{x}_i)$은 y축으로 한 그래프를 그림.

    만약 4개의 관측치가 존재한다면,

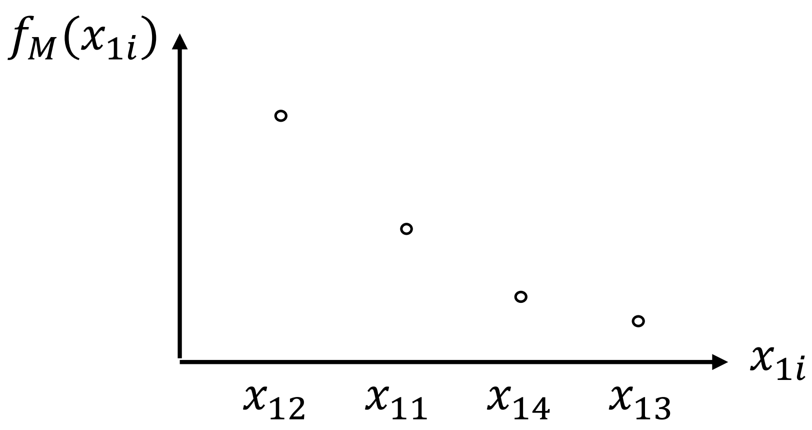

Q & A